

Self-supervised Learning for Large-scale Item Recommendations

Tiansheng Yao, Xinyang Yi, Derek Zhiyuan Cheng, Felix Yu, Ting Chen, Aditya Menon
Lichan Hong, Ed H. Chi, Steve Tjoa, Jieqi (Jay) Kang, Evan Ettinger
Google Inc., United States

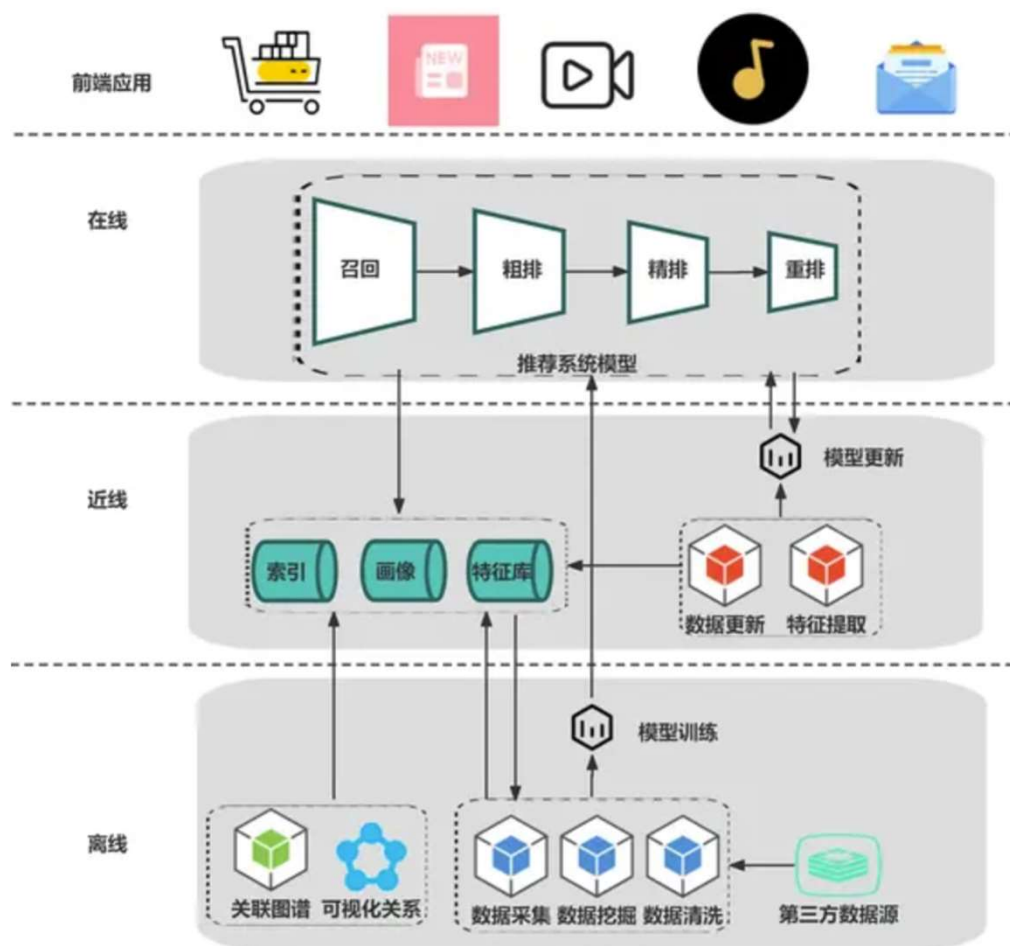
CIKM 2021

Background

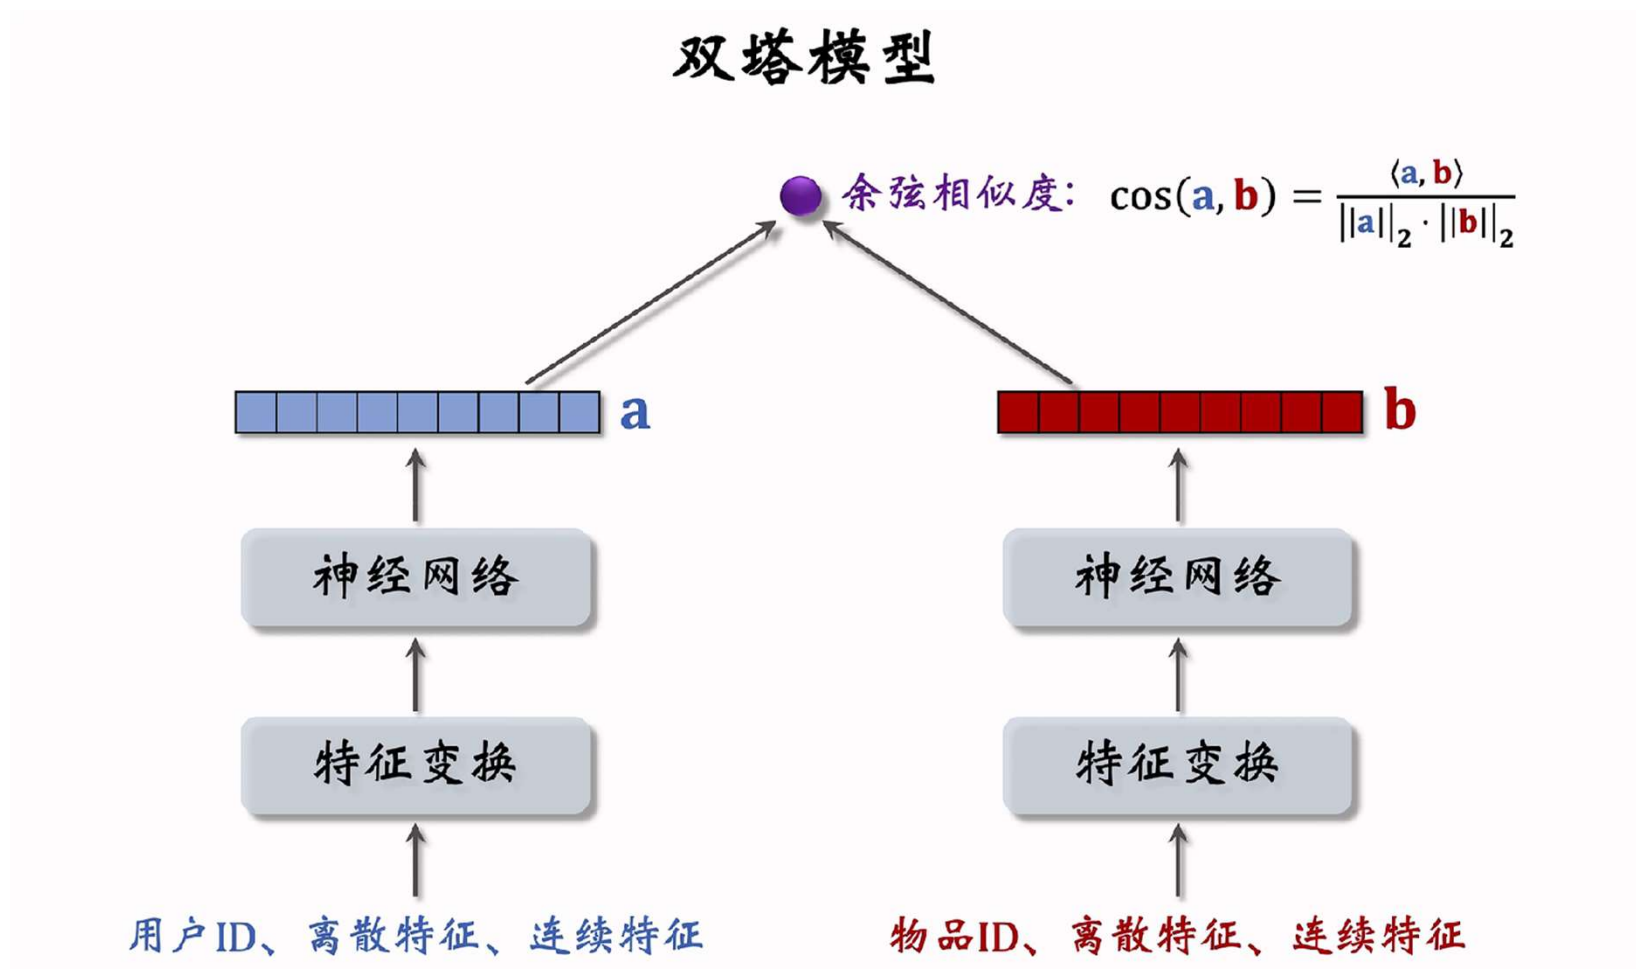


南京航空航天大学
NANJING UNIVERSITY OF AERONAUTICS AND ASTRONAUTICS

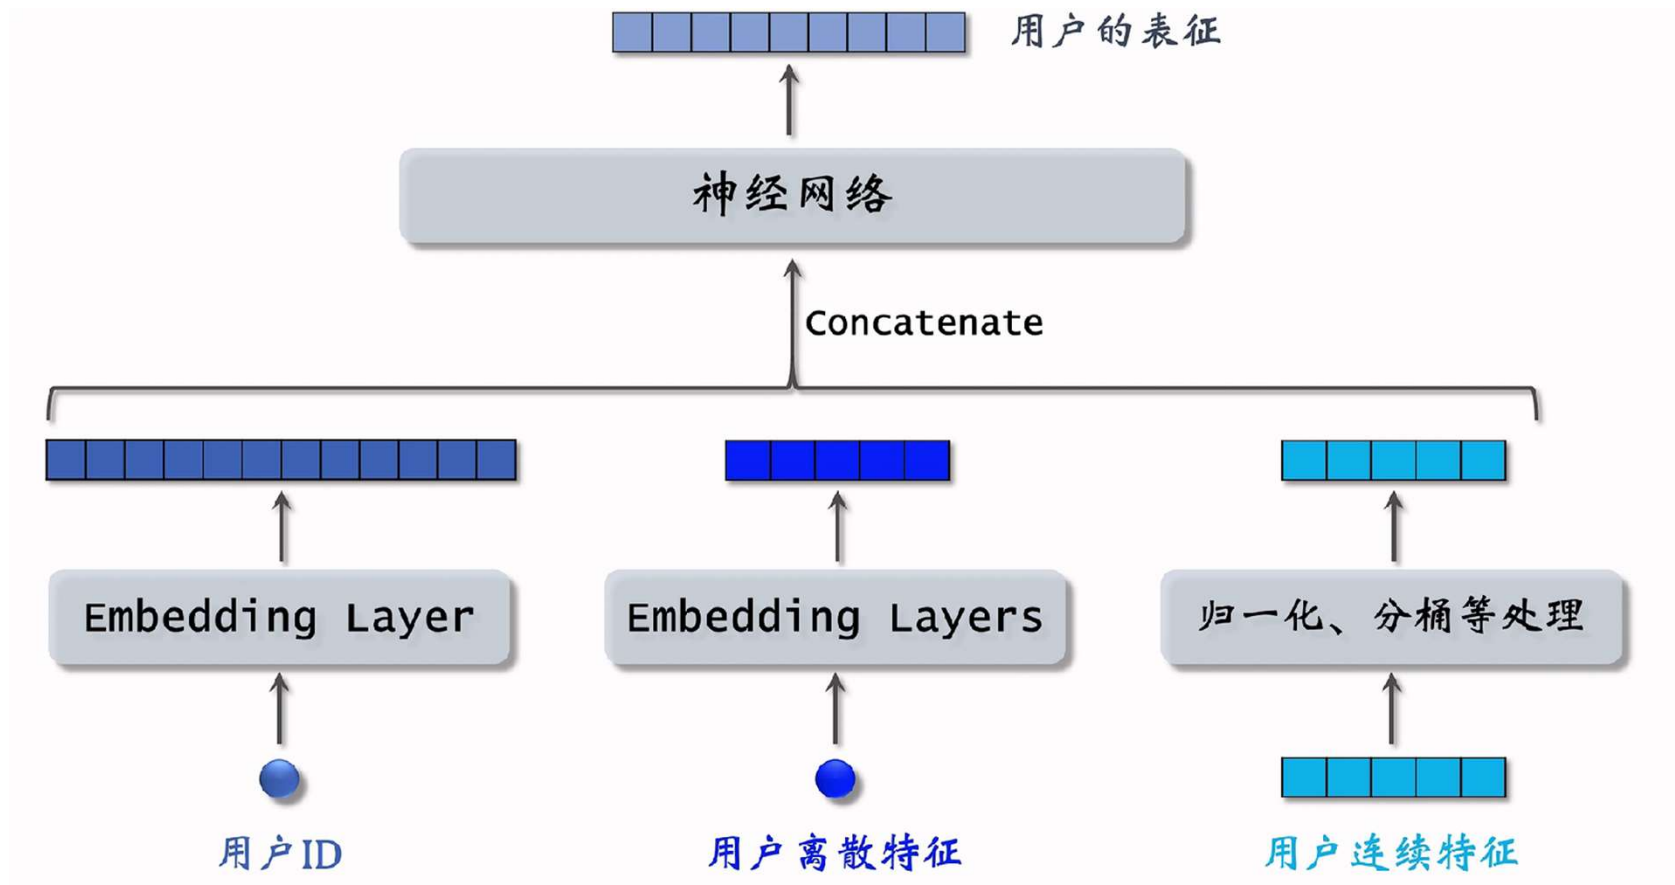
推荐系统架构



Background




Background



Background

Batch内负样本



- 物品 j 被抽样到的概率:

$$p_j \propto \text{点击次数}$$


- 预估用户 i 对物品 j 的兴趣: $\cos(\mathbf{a}_i, \mathbf{b}_j)$

- 做训练的时候, 把 $\cos(\mathbf{a}_i, \mathbf{b}_j)$ 替换为:

$$\cos(\mathbf{a}_i, \mathbf{b}_j) - \log p_j$$

- 一个 batch 内有 n 对正样本。
- 组成 n 个 list, 每个 list 中有 1 对正样本和 $n-1$ 对负样本。

Listwise loss

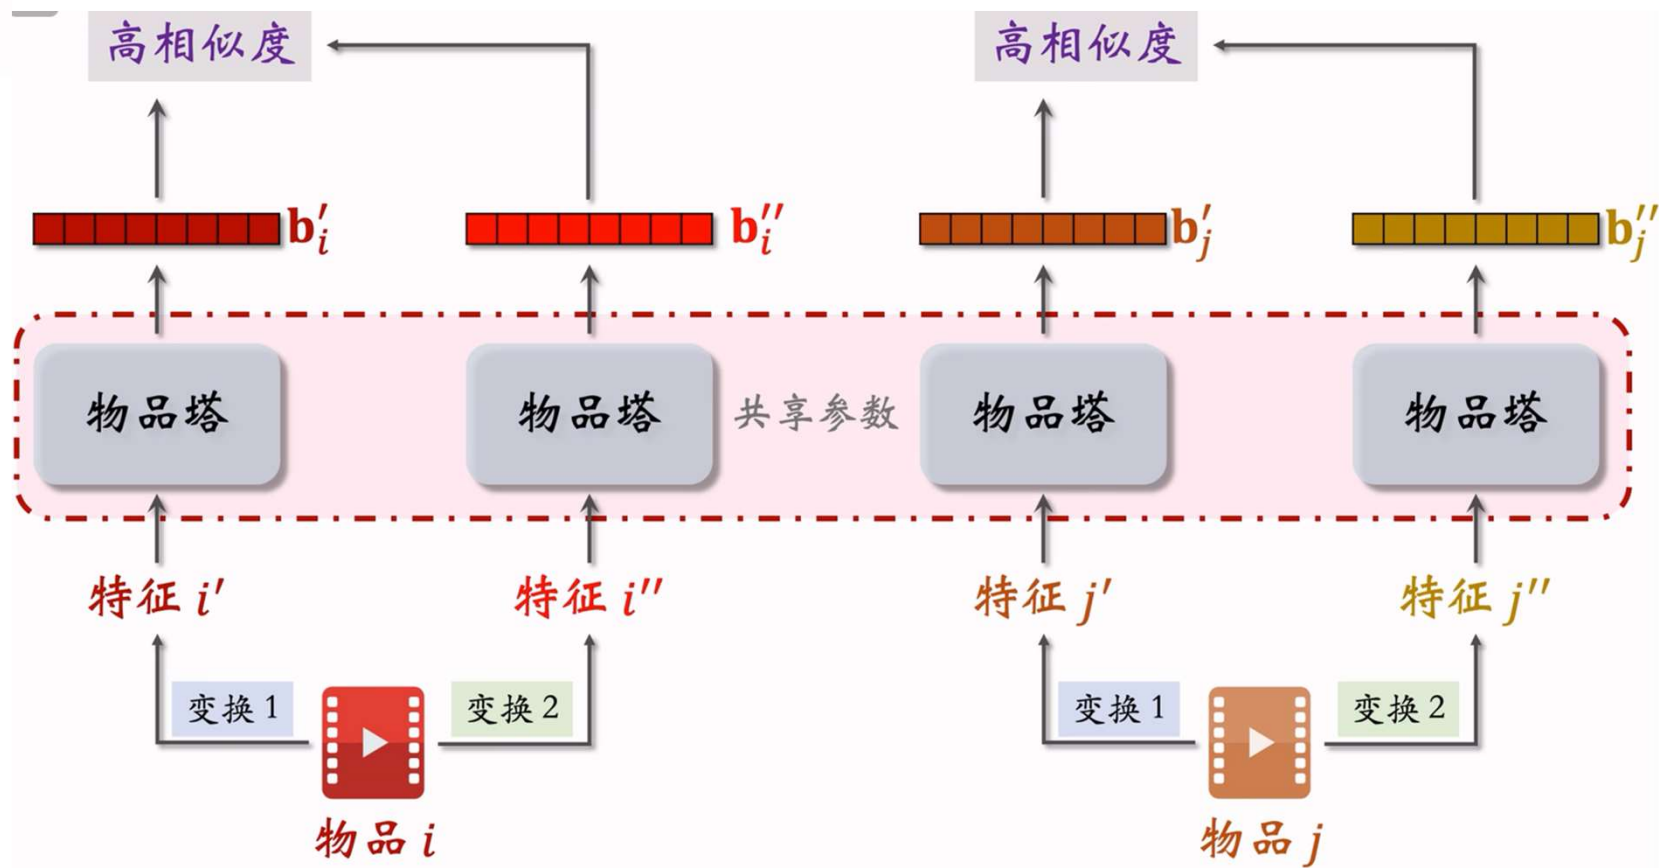


双塔模型的问题

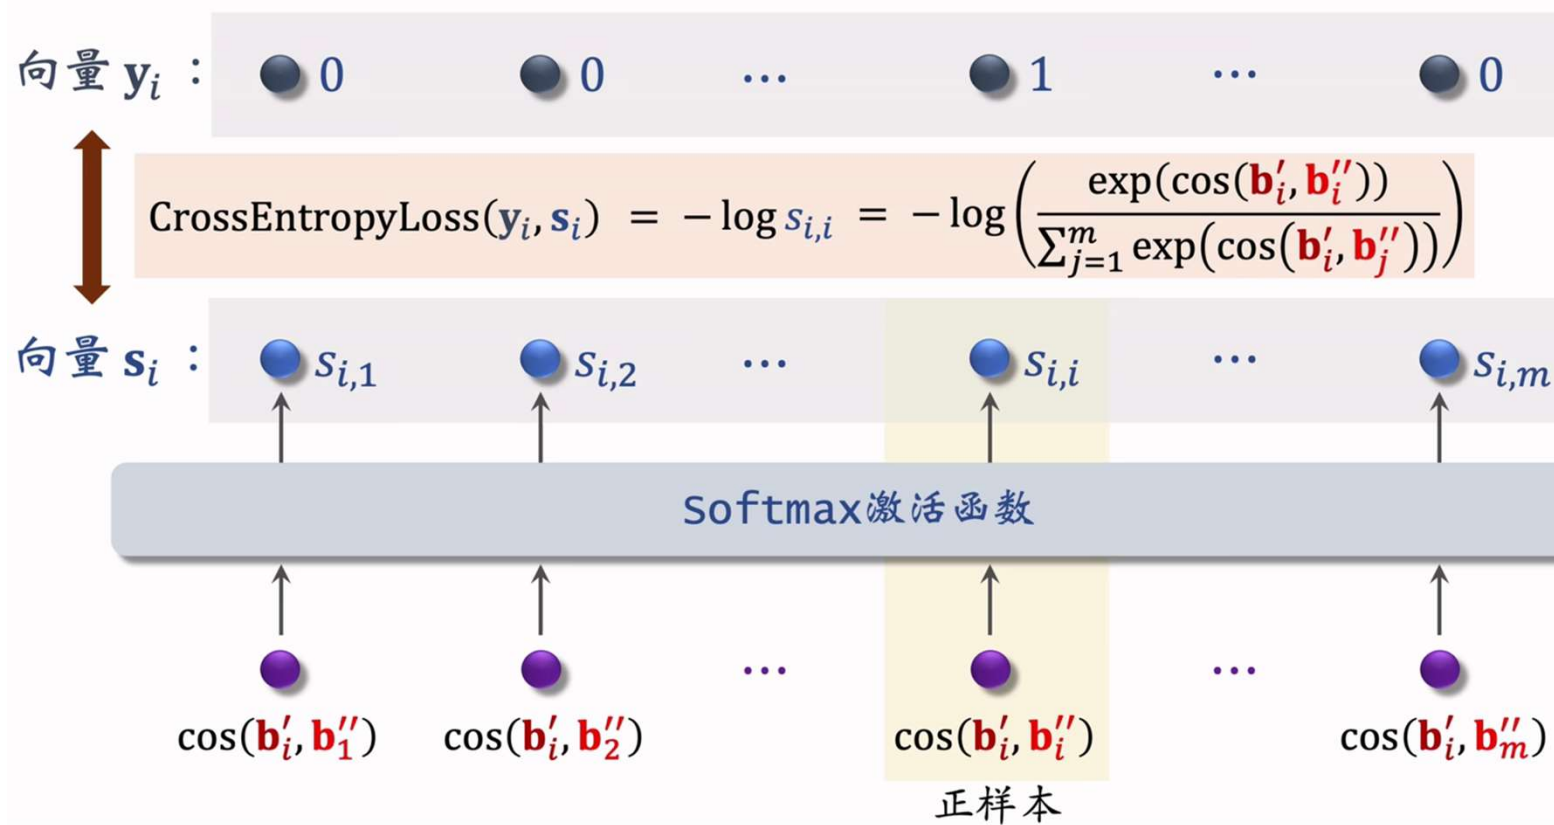
- 推荐系统的头部效应严重：
 - 少部分物品占据大部分点击。
 - 大部分物品的点击次数不高。
- 高点击物品的表征学得好，长尾物品的表征学得不好。
- 自监督学习：做 data augmentation，更好地学习长尾物品的向量表征。

曝光 → 点击 → 转化

Methods



Methods



特征变换：Random Mask

- 随机选一些离散特征（比如类目），把它们遮住。
- 例：
 - 某物品的类目特征是 $u = \{\text{数码}, \text{摄影}\}$ 。
 - Mask 后的类目特征是 $u' = \{\text{default}\}$ 。

特征变换：Dropout（仅对多值离散特征生效）

- 一个物品可以有多个类目，那么类目是一个多值离散特征。
- Dropout：随机丢弃特征中 50% 的值。
- 例：
 - 某物品的类目特征是 $U = \{\text{美妆}, \text{摄影}\}$ 。
 - Dropout 后的类目特征是 $U' = \{\text{美妆}\}$ 。

特征变换：互补特征 (complementary)

- 假设物品一共有 4 种特征：

ID，类目，关键词，城市

- 随机分成两组：

{ID，关键词} 和 {类目，城市}

- { ID，default，关键词，default } → 物品表征
- { default，类目，default，城市 } → 物品表征

鼓励两个向量相似

特征变换：Mask 一组关联的特征

- 受众性别： $\mathcal{U} = \{\text{男}, \text{女}, \text{中性}\}$
- 类目： $\mathcal{V} = \{\text{美妆}, \text{数码}, \text{足球}, \text{摄影}, \text{科技}, \dots\}$
- $u = \text{女}$ 和 $v = \text{美妆}$ 同时出现的概率 $p(u, v)$ 大。
- $u = \text{女}$ 和 $v = \text{数码}$ 同时出现的概率 $p(u, v)$ 小。
- $p(u)$ ：某特征取值为 u 的概率。
- $p(u, v)$ ：某特征取值为 u ，另一个特征取值为 v ，同时发生的概率。
- 离线计算特征两两之间的关联，用互信息（mutual information）衡量：

$$MI(\mathcal{U}, \mathcal{V}) = \sum_{u \in \mathcal{U}} \sum_{v \in \mathcal{V}} p(u, v) \cdot \log \frac{p(u, v)}{p(u) \cdot p(v)}.$$

Methods

- 对点击做随机抽样，得到 n 对用户—物品二元组，作为一个 batch。
- 从全体物品中均匀抽样，得到 m 个物品，作为一个 batch。
- 做梯度下降，使得损失减小：

$$\frac{1}{n} \sum_{i=1}^n L_{\text{main}}[i] + \alpha \cdot \frac{1}{m} \sum_{j=1}^m L_{\text{self}}[j].$$

双塔模型的损失

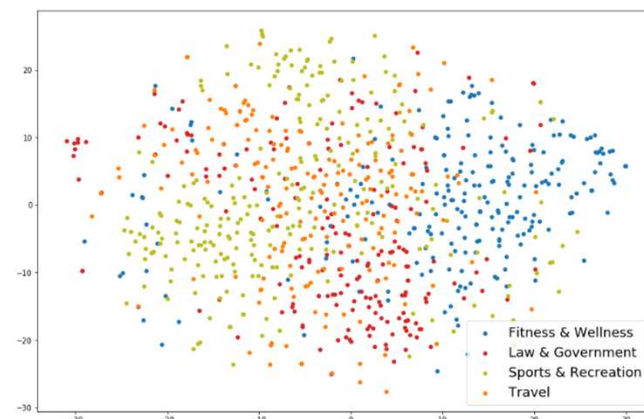
自监督学习的损失

Experiments


实验效果：Youtube自身，包括小红书的复现，都取得了显著效果，新曝光物品和新物品的推荐变得准确

Wikipedia				
Method	Tail		Head	
	Recall@10	Recall@50	Recall@10	Recall@50
Baseline	0.0472	0.1621	0.0610	0.2273
FD	0.0474	0.1638	0.0593	0.2212
SO	0.0481	0.1644	0.0606	0.2268
Our method	0.0524	0.1749	0.0619	0.2283
AAI				
Baseline	0.0475	0.2333	0.2846	0.4993
FD	0.0727	0.2743	0.2849	0.5069
SO	0.0661	0.2602	0.2879	0.5086
Our method	0.0720	0.2906	0.309	0.537

Table 3: Results of Wikipedia and AAI on tail and head item slices.



(a) Baseline Model



(b) Best SSL Model

Deep Interest Network for Click-Through Rate Prediction

Guorui Zhou, Chengru Song, Xiaoqiang Zhu
Ying Fan, Han Zhu, Xiao Ma, Yanghui Yan, Junqi Jin, Han Li, Kun Gai

Alibaba Group

{guorui.xgr,chengru.scr,xiaoqiang.zxq,zhuhuan.zh,fanying.fy,maxiao.ma,yanghui.yyh,junqi.jjq,lihan.hl,jingshi.gk}@
alibaba-inc.com

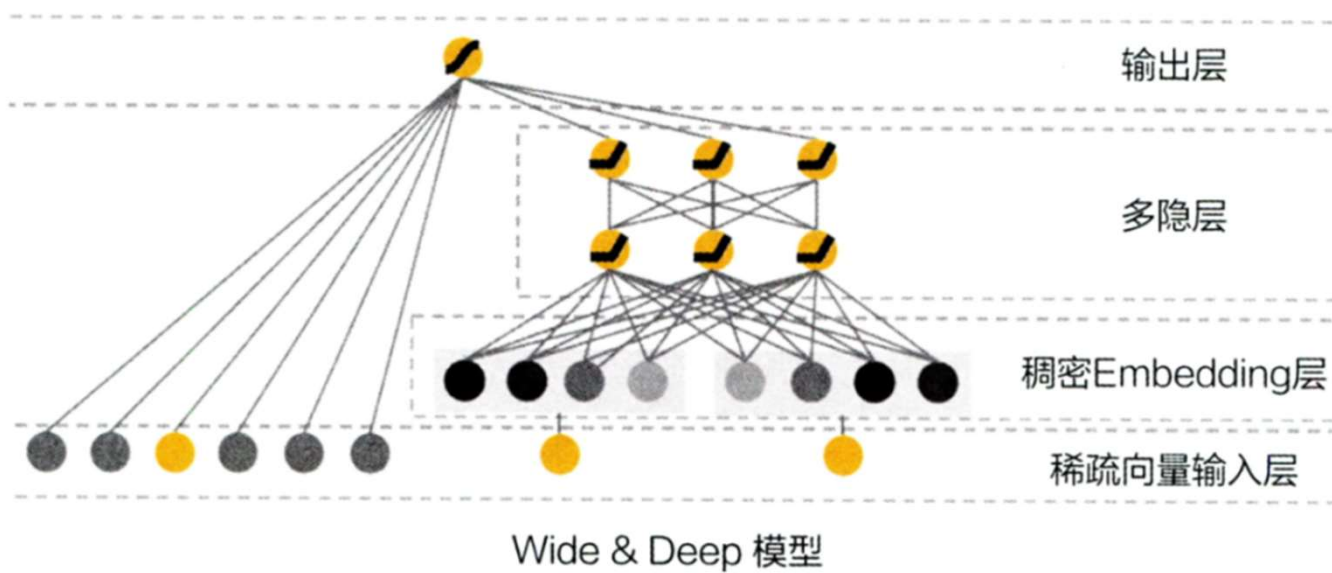
KDD 2018

Background



南京航空航天大学
NANJING UNIVERSITY OF AERONAUTICS AND ASTRONAUTICS

经典精排模型 Wide&Deep



Motivation

- 用户历史行为数据利用

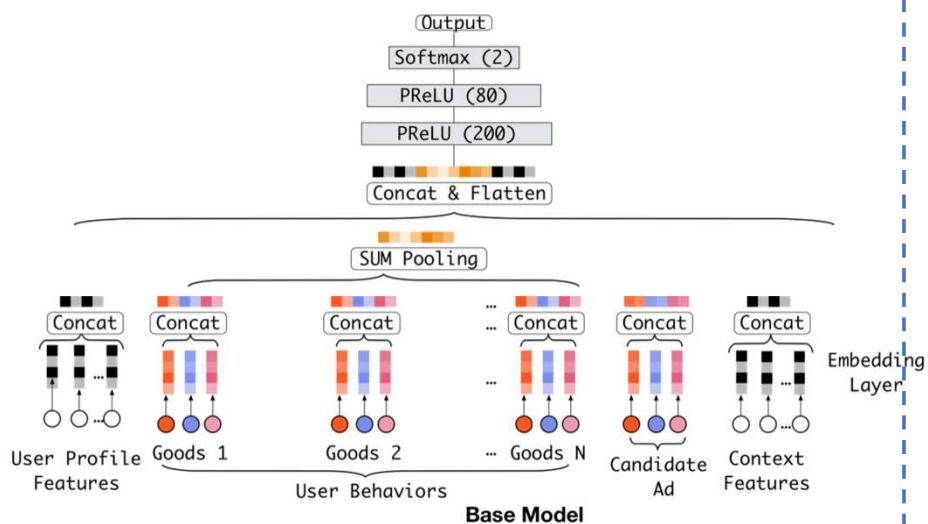


Methods

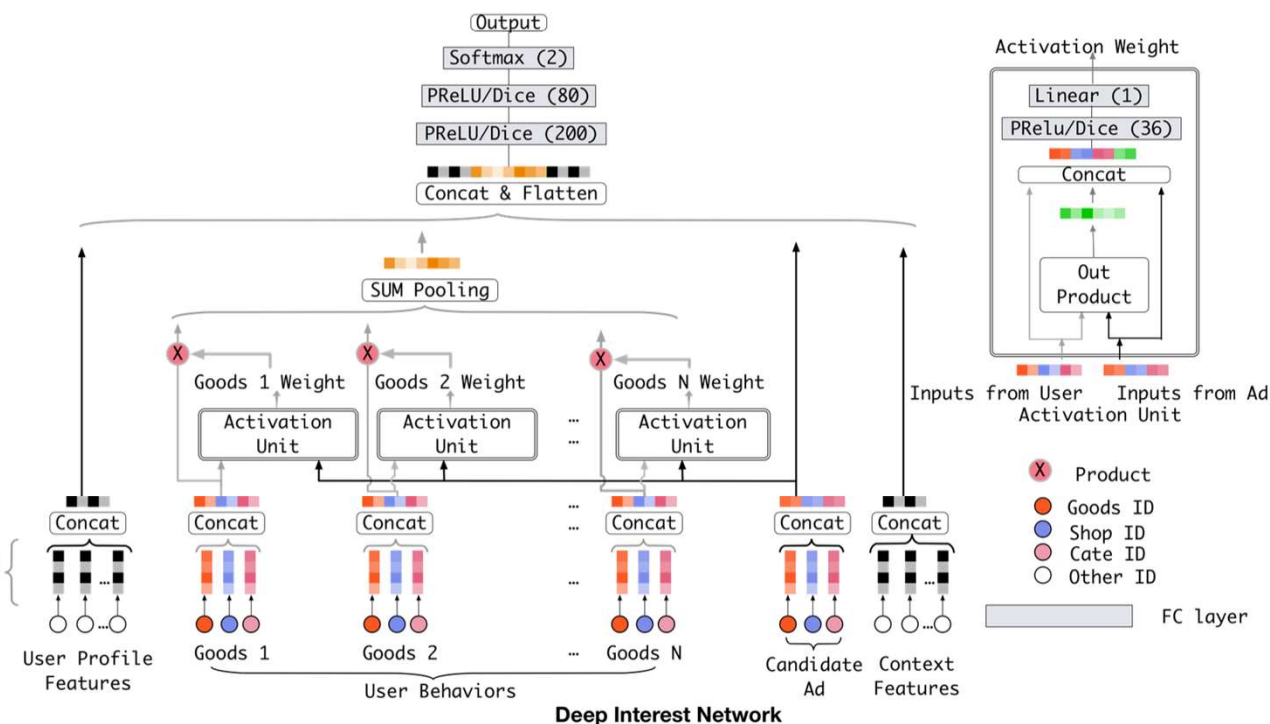


南京航空航天大学
NANJING UNIVERSITY OF AERONAUTICS AND ASTRONAUTICS

旧方法结构



DIN结构



Experiments


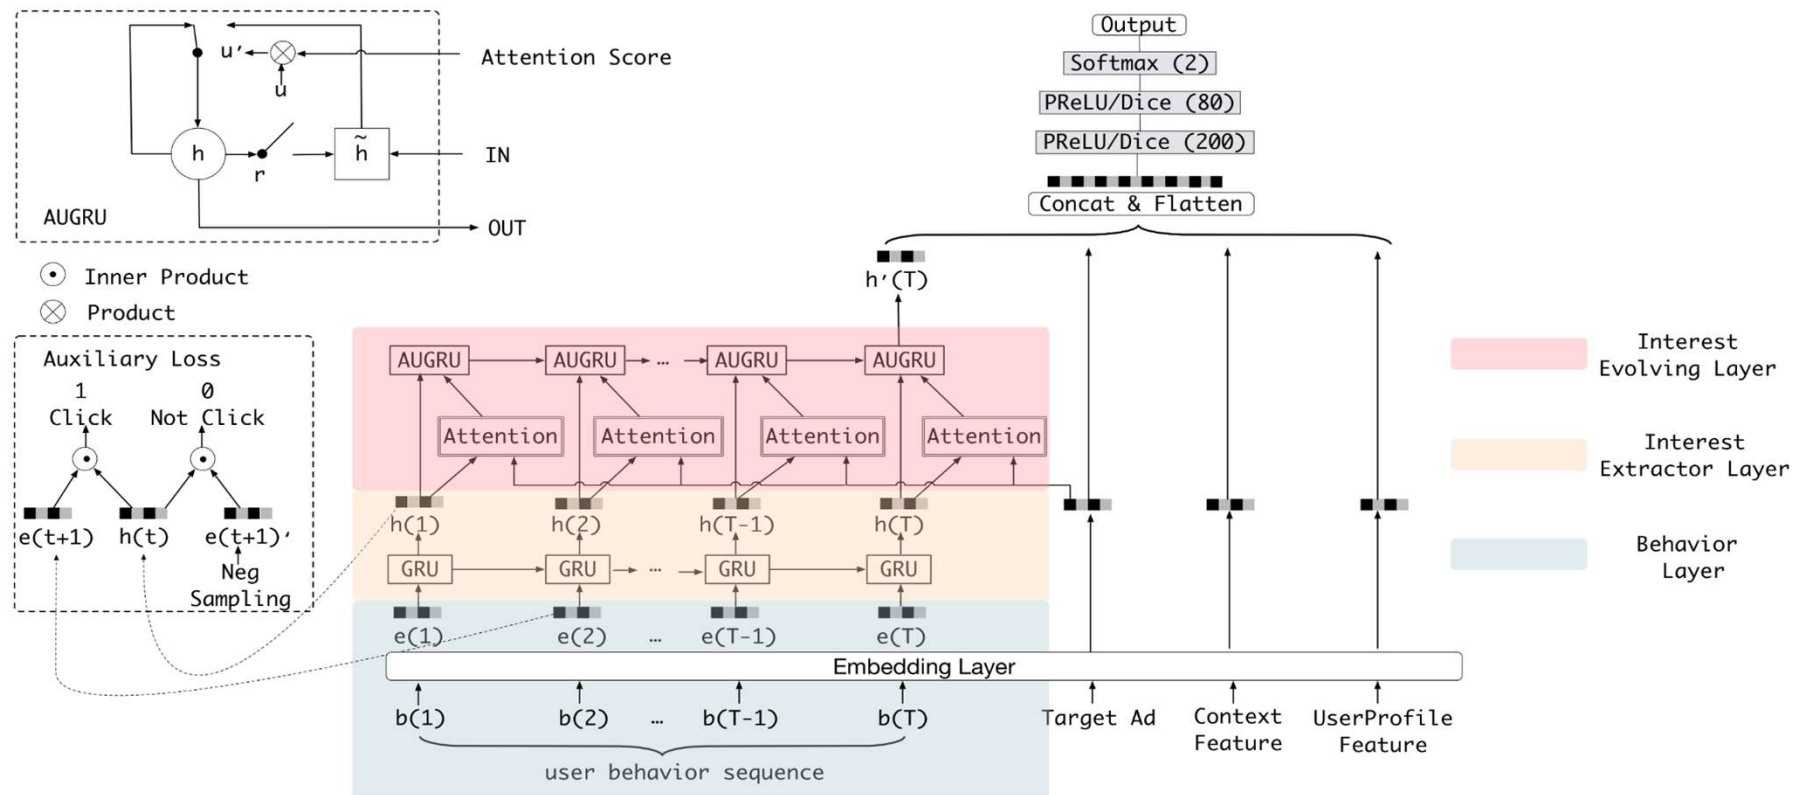


Figure 6: Visualization of embeddings of goods in DIN. Shape of points represents category of goods. Color of points corresponds to CTR prediction value.

• Deep Interest Evolution Network (DIEN)



Thanks